Einführung in Data Engineering

Rolle, Plattformarchitektur und Abgrenzung zu Data Science

Dr.-Ing. Grigory Devadze

Was ist Data Engineering?

Data Engineering ist der Aufbau und Betrieb von Systemen, die Daten:

- erfassen,
- speichern,
- transformieren,
- verlässlich für Analyse und Produkte bereitstellen.

Kernidee:

- **Aus Rohdaten werden nutzbare Datenprodukte.**

Warum Data Engineering wichtig ist

Ohne Data Engineering entstehen häufig:

- inkonsistente Kennzahlen,
- manuelle Excel-Prozesse,
- langsame oder fehleranfällige Reports,
- geringe Vertrauenswürdigkeit von Daten.

Mit Data Engineering:

- skalierbare und reproduzierbare Datenflüsse,
- bessere Entscheidungsqualität,
- schnellere Time-to-Insight.

Rolle des Data Engineers: Überblick

Ein Data Engineer verantwortet typischerweise:

- Datenintegration aus verschiedenen Quellen,
- Entwicklung von ETL/ELT-Pipelines,
- Datenmodellierung für Analytics,
- Betrieb, Monitoring und Optimierung,
- Datenqualität und Governance-Bausteine.

Typische Aufgaben im Alltag

- Quellsysteme anbinden (API, DB, Streams)
- Ingestion und Transformation implementieren
- Datenmodelle (z. B. Fact/Dimension) entwickeln
- Ladeprozesse orchestration/automatisieren
- Fehleranalyse, Incident-Behebung, Performance-Tuning

Skills eines Data Engineers

Technisch:

- SQL, Python, Datenmodellierung
- Cloud-/Storage-Konzepte, verteilte Verarbeitung
- Orchestrierung, CI/CD, Monitoring

Arbeitsweise:

- systemisches Denken,
- saubere Dokumentation,
- Zusammenarbeit mit Analytics, BI und Data Science.

Architektur von Datenplattformen

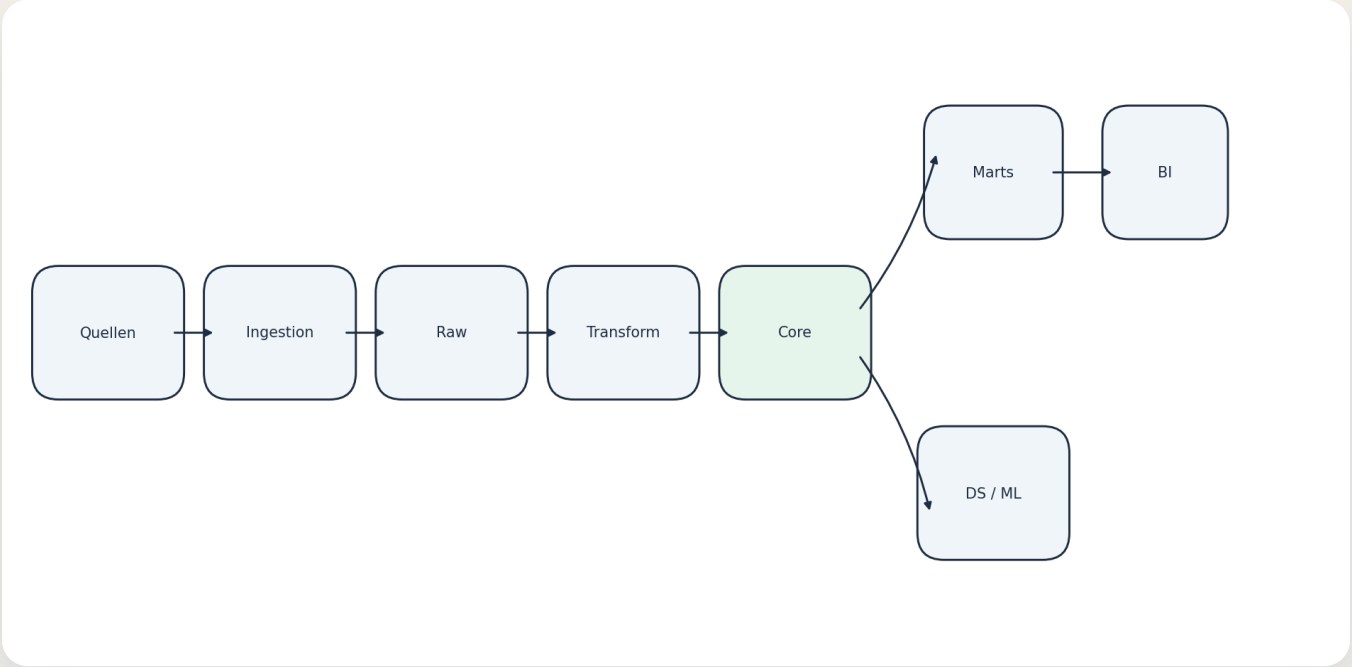

Architektur-Bausteine erklärt

- **Ingestion:** Daten zuverlässig einsammeln (batch/stream)
- **Storage:** Rohdaten + kuratierte Daten speichern
- **Transformation:** fachliche Logik, Harmonisierung, Anreicherung
- **Serving Layer:** Daten für BI, APIs, ML nutzbar machen
- **Observability:** Monitoring, Logging, Data Quality

Batch vs. Streaming in der Plattform

- **Batch:** periodische Verarbeitung, robust und planbar
- **Streaming:** ereignisnahe Verarbeitung, niedrige Latenz

Praxis:

- viele Plattformen nutzen hybride Ansätze,
- Wahl hängt von Business-Anforderung an Datenfrische ab.

Data Engineering vs. Data Science

Aspekt	Data Engineering	Data Science
Fokus	Datenbereitstellung & Plattform	Analyse, Modelle, Erkenntnisse
Kernfrage	„Wie liefern wir verlässliche Daten?“	„Was sagen die Daten voraus/aus?“
Artefakte	Pipelines, Modelle, Datenprodukte	Features, Experimente, Modelle
Erfolgskriterium	Stabilität, Qualität, Skalierung	Modellgüte, Business-Impact

Zusammenarbeit DE + DS (Idealbild)

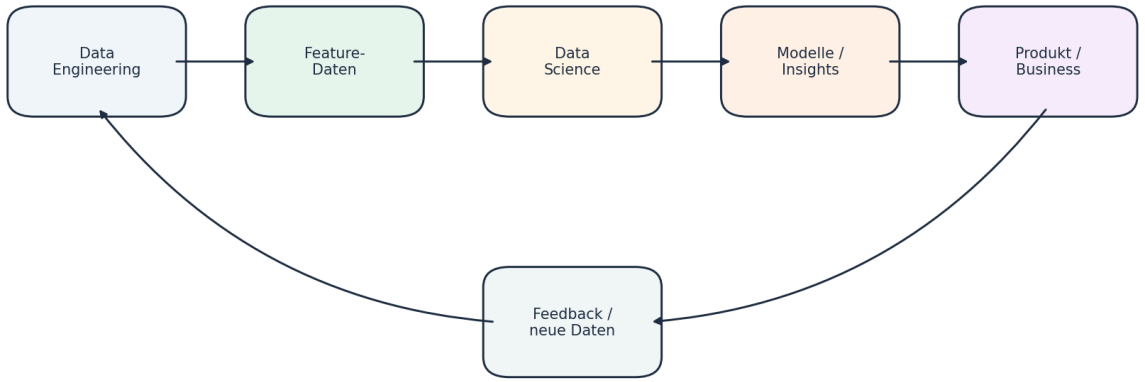

Häufige Missverständnisse

- „Data Engineer = nur ETL-Skripte“
- „Data Science braucht keine Plattformdisziplin“
- „Mehr Tools lösen automatisch Datenprobleme“

Real Cases aus der Praxis

- E-Commerce: Daily KPI-Reports auf nahezu Echtzeit umgestellt.
- Industrie/IoT: Sensordaten von Batch auf Streaming umgestellt.
- Finanz/Compliance: Data Lineage und Audit-Reporting stabilisiert.

Case 1: E-Commerce (Umsatz- und Funnel-Reporting)

Ausgangslage:

- KPI-Reports kamen nur 1x täglich.
- Marketing und Ops reagierten mit starker Verzögerung.

Data-Engineering-Maßnahmen:

- Event-Ingestion + inkrementelle Transformationen.
- Kuratierte Marts für Checkout/Funnel/Retention.
- Data-Quality-Checks auf Pflichtfelder und Duplikate.

Ergebnis:

- Reporting-Latenz von ~24h auf <30min gesenkt.
- Schnellere Kampagnenanpassungen und weniger Fehlentscheidungen.

Case 2: IoT/Produktion (Anomalie-Erkennung)

Ausgangslage:

- Maschinendaten wurden nur als Tagesbatch verarbeitet.
- Störungen wurden oft erst im Nachhinein erkannt.

Data-Engineering-Maßnahmen:

- Streaming-Pipeline mit Fenster-Aggregationen.
- Trennung in Raw, Curated und Alert-Serving-Layer.
- Monitoring für Verzögerung, Ausfallrate und Datenlücken.

Ergebnis:

- Frühere Erkennung von Grenzwertverletzungen.
- Weniger ungeplante Stillstände und bessere Wartungsplanung.

Case 3: Finance/Compliance (Audit und Nachvollziehbarkeit)

Ausgangslage:

- Reports wurden aus vielen manuellen Quellen zusammengeführt.
- Hoher Abstimmungsaufwand bei Audit-Anfragen.

Data-Engineering-Maßnahmen:

- Standardisierte Transformationslogik mit versionierten Pipelines.
- Lineage von Quelle bis Kennzahl dokumentiert.
- Reproduzierbare Monats-Snapshots für Audit-Trails.

Ergebnis:

- Deutlich weniger manuelle Nacharbeit.
- Schnellere und belastbare Antworten für Revision/Compliance.

Best Practices für den Einstieg

1. Erst Datenmodell klären, dann bauen.
2. Pipeline-Tests und Datenqualitätschecks früh einbauen.
3. Ownership für Tabellen/Produkte definieren.
4. Monitoring/Latenz/Fehlerquoten transparent machen.
5. Dokumentation als Teil der Lieferung behandeln.

Zusammenfassung

- Data Engineering schafft die technische Grundlage für datengetriebene Entscheidungen.
- Data Engineers bauen und betreiben Datenplattformen als verlässliche Produkte.
- Gute Plattformarchitektur verbindet Quellen, Transformation und Konsum klar.
- Data Engineering und Data Science sind komplementär und wirken am stärksten gemeinsam.